



KHALIL BEN ALI

— Full-Stack & AI Engineer

Faenza, Italie · khalil.benali16121@gmail.com · github.com/khalilBenAli1 · linkedin.com/in/khalil-ben-ali

PROFIL

Développeur full-stack (5+ ans) : plateformes TypeScript, applications desktop .NET et IA en production. Ingénieur principal d'un hub opérationnel IA intégrant 10 systèmes SaaS pour un cabinet financier américain ; seul développeur d'une expérience de marque IA pour L'OR (JDE). Prend les systèmes en main de bout en bout, du schéma de données au WebGL, du prompt à la file d'impression.

EXPÉRIENCE

nBold — Développeur Full-Stack & IA · 2024 → auj. · télétravail (siège à Paris)

nBold édite un SaaS de templates et de gouvernance d'espaces Microsoft Teams (ISO 27001, SOC 2).

- Conception et développement de bout en bout de la fonctionnalité d'intelligence de réunions Teams (~11 000 lignes, 67 fichiers, 321 tests) : capture des transcriptions via Microsoft Graph avec un nouveau chemin d'authentification app-only, résumé par IA et routage LLM contextualisé CRM vers des Adaptive Cards Teams, sur des workflows durables prouvés résistants aux crashes.
- Ingénieur principal de Cuddy Brain, hub opérationnel intégré à Teams qui réplique 10 systèmes SaaS dans PostgreSQL (~115 tables) ; ~3 860 commits, environ 69 % de l'historique backend (NestJS, BullMQ/Redis, React, Azure OpenAI).
- Livraison de l'intelligence d'appels : les appels sont transcrits, résumés par Azure OpenAI et transformés en tâches publiées dans Teams en Adaptive Cards quelques minutes après la fin de l'appel, avec verrouillage single-flight et reprise après incident.
- Développement de systèmes de surveillance IA (adjudication de décès avec contrôles déterministes ; détection de déménagements croisant registres publics et communications clients) et co-développement d'un agent LangGraph qui compile des revues clients à partir de 7 systèmes.
- Fiabilisation de la plateforme : client Azure OpenAI partagé avec timeouts, retries et suivi de consommation, vérification HMAC des webhooks, CI de détection de secrets, cache et optimisations N+1.
- Seul développeur de L'OR UNLIMITED REMIX (JDE × HLWN 2026), app de marque IA et borne événementielle : Gemini avec repli déterministe, vision CLIP embarquée, moteur de fluide WebGL à 60 fps, PWA offline-first et impression thermique Bluetooth. 129/129 commits, ~24 600 lignes, 11 semaines jusqu'à la production.
- Développement de Cuddy Scanner, scanner de documents .NET 9/WPF (TWAIN, séparation par code-barres, assemblage PDF, classement SharePoint) utilisé quotidiennement en production.

Freelance — Développeur logiciel · 2023 → 2024

- Jeu pour enfants (React Native, Expo, Redux) et planificateur de voyage multiplateforme (React Native + MobX, backend Express/MongoDB, admin React).

SolvR — Développeur logiciel · 2023

- Refonte et livraison d'une app de chat multiplateforme (React Native, Expo, MobX, Firebase) : messagerie temps réel, authentification sécurisée, architecture d'état.

Tynass IT — Développeur logiciel · 2019 → 2022

- Livraison d'une app de tourisme en réalité augmentée, d'une plateforme d'emploi, d'un e-commerce mode et de sites d'entreprise (React, Material-UI, Express, MongoDB).

COMPÉTENCES

TypeScript · React/Next.js · React Native · NestJS/Node · PostgreSQL · Redis/BullMQ · Azure OpenAI · Gemini · LangGraph · RAG (pgvector) · transformers.js · C#/.NET 9 · WPF · C++20/JUCE · Microsoft Graph & Teams · Salesforce · Docker · GitHub Actions · Vercel

PROJETS PERSONNELS

- HyperMesh DSP & HyperGpu (C++20/JUCE) : maillage LAN pour le dépôt de DSP temps réel et hôte de plugins accéléré GPU ; builds CI pour 5 plateformes.
- Assurances BIAT KB : chatbot RAG explicable (NestJS, pgvector, Ollama), réponses citées et journal d'audit RBAC.

FORMATION

Licence en communication multimédia, Institut Supérieur des Arts Multimédia de la Manouba (ISAMM), 2019

LANGUES

Arabe (natif) · Anglais (professionnel) · Français (A2-B1) · Italien (A2)